

EEE933 - Estudo de Caso 01: Comparação do IMC médio de alunos do PPGE-UFMG entre os semestres 2016-2 e 2017-2

Amanda Bomfim Moitinho, David Felipe Brochero Giraldo, Henrique Marques Cruz

13/09/2026

Resumo

Este estudo compara o Índice de Massa Corporal (IMC) médio de alunos de pós-graduação do PPGE-UFMG entre os semestres 2016-2 e 2017-2, separando a análise por sexo. Foram conduzidos testes t de Welch para duas amostras independentes, com verificação de premissas (normalidade via Shapiro-Wilk, homogeneidade de variância via teste de Fligner-Killeen) e teste de Wilcoxon como checagem de robustez. Para o grupo feminino, não foi encontrada diferença estatisticamente significativa ao nível $\alpha = 0.05$ ($p = 0.060$), com tamanho de efeito observado grande ($d \approx 1.21$). Para o grupo masculino, também não há diferença significativa ($p = 0.593$) e o efeito observado é pequeno ($d \approx 0.17$). Ao fixar a priori um tamanho de efeito mínimo relevante ($\delta^* = 1.0$ kg/m²), a potência do teste é baixa nos **dois** grupos — $\approx 10.9\%$ nas mulheres ($n = 7$ e $n = 4$) e $\approx 12.5\%$ nos homens ($n = 21$ em cada semestre), esta última penalizada pelo desvio-padrão do IMC masculino (≈ 3.90) ser quase o dobro do feminino (≈ 2.05). Ambos os resultados são, portanto, inconclusivos quanto à existência de uma diferença de pelo menos 1.0 kg/m² entre os semestres.

Desenho experimental

Descrição do problema

Neste estudo deseja-se comparar o Índice de Massa Corporal (IMC) médio de duas populações como um valor proxy para variáveis relativas ao estilo de vida dos indivíduos. As amostras fornecem os dados de peso, altura e sexo de alunos de pós-graduação em Engenharia Elétrica na UFMG nos semestres 2016-2 e 2017-2.

Hipóteses

A amostra foi estratificada por sexo e dois testes independentes foram conduzidos, um para cada subpopulação:

$$\begin{array}{ll} \text{Mulheres:} & \begin{cases} H_0 : \mu_{F,2016} = \mu_{F,2017} \\ H_1 : \mu_{F,2016} \neq \mu_{F,2017} \end{cases} & \text{Homens:} & \begin{cases} H_0 : \mu_{M,2016} = \mu_{M,2017} \\ H_1 : \mu_{M,2016} \neq \mu_{M,2017} \end{cases} \end{array}$$

Foram utilizadas hipóteses bilaterais por não haver razão a priori para esperar que o IMC tenha subido ou descido de um semestre para o outro. O nível de significância adotado é $\alpha = 0.05$ por teste.

Tamanho de efeito mínimo relevante (δ^*)

Tendo em vista que não há um consenso de diferença mínima clinicamente importante (MCID, do inglês *Minimal Clinically Important Difference*), definiu-se como tamanho de efeito mínimo relevante $\delta^* = 1.0$ kg/m², tendo como base os estudos [1], [2] e [3], que associam a alteração de 1 unidade de IMC à melhora da qualidade de vida relacionada à saúde em adultos e crianças. Ressalta-se que esses estudos foram conduzidos em populações com obesidade e/ou em contexto de intervenção de perda de peso — nenhuma delas corresponde exatamente à população deste estudo (provavelmente adultos, sem diagnóstico de obesidade) —, e que MCID descreve tipicamente mudança intraindividual ao longo do tempo; aqui o valor é usado como uma

aproximação conservadora para ancorar a análise de potência a priori, e não como uma estimativa específica para a população deste estudo.

```
mcid <- 1.0 # delta* (MCID) adotado, em kg/m^2
```

Descrição da coleta e consolidação dos dados

Os dois arquivos fornecidos têm formatos diferentes, exigindo consolidação:

- `imc_20162.csv`: separado por vírgula, colunas `ID`, `Course`, `Gender`, `Height.m`, `Weight.kg`. Contém alunos de dois cursos (PPGEE e ENGSIS/graduação); os registros de ENGSIS foram excluídos, pois o escopo do estudo é a pós-graduação em Engenharia Elétrica.
- `CS01_20172.csv`: separado por ponto-e-vírgula, colunas `Weight.kg`, `height.m`, `Sex`, `Age.years` (sem coluna de curso e sem ID, mas com idade).

Suposição explícita: como o arquivo de 2017-2 não tem coluna de curso e o enunciado só menciona mistura de turmas para o arquivo de 2016-2, assumimos que todos os registros de `CS01_20172.csv` já são de alunos do PPGEE.

```
d16 <- read.csv("imc_20162.csv", stringsAsFactors = FALSE)
d17 <- read.csv("CS01_20172.csv", sep = ";", stringsAsFactors = FALSE)

d16 <- d16[d16$Course == "PPGEE", ]

d16$BMI <- d16$Weight.kg / (d16$Height.m^2)
d17$BMI <- d17$Weight.kg / (d17$height.m^2)

df <- data.frame(
  Semestre = factor(c(rep("2016-2", nrow(d16)), rep("2017-2", nrow(d17))),
    levels = c("2016-2", "2017-2")),
  Sexo      = factor(c(d16$Gender, d17$Sex), levels = c("F", "M"),
    labels = c("Feminino", "Masculino")),
  Altura    = c(d16$Height.m, d17$height.m),
  Peso      = c(d16$Weight.kg, d17$Weight.kg),
  IMC       = c(d16$BMI, d17$BMI)
)
```

Análise Exploratória

A Tabela 1 apresenta o número de observações por grupo, estratificado por sexo e semestre.

Tabela 1: Número de observações por grupo

	Feminino	Masculino
2016-2	7	21
2017-2	4	21

O grupo feminino de 2017-2 tem apenas 4 observações, bem menos que os demais grupos (7, 21 e 21). Isso já é um sinal de alerta para a potência do teste correspondente.

A Tabela 2 resume as estatísticas descritivas do IMC por grupo: média, desvio-padrão (DP) e mediana.

Tabela 2: Estatísticas descritivas do IMC por grupo

Semestre	Sexo	n	Media	DP	Mediana
2016-2	Feminino	7	21.08	2.42	20.20
2017-2	Feminino	4	18.45	1.60	17.80
2016-2	Masculino	21	24.94	4.32	24.36
2017-2	Masculino	21	24.29	3.44	23.75

A Figura 1 ilustra a distribuição do IMC por semestre, separada por sexo.

```
ggplot(df, aes(x = Semestre, y = IMC, fill = Semestre)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA) +
  geom_jitter(width = 0.1, alpha = 0.6) +
  facet_wrap(~ Sexo) +
  labs(y = "IMC (kg/m²)", x = NULL) +
  theme_minimal() +
  theme(legend.position = "none")
```




Figura 1: IMC por semestre, separado por sexo

O IMC médio feminino aparenta cair de 2016-2 para 2017-2, enquanto o masculino se mantém praticamente estável. A dispersão é visivelmente maior no grupo masculino, e o grupo feminino de 2017-2 tem poucos pontos e pouca variabilidade aparente, mas isso pode ser só efeito do n pequeno.

Análise Estatística

Teste de hipóteses, tamanho de efeito e intervalo de confiança

```
cohend <- function(x, y) {
  nx <- length(x); ny <- length(y)
```

```

sp <- sqrt(((nx - 1) * var(x) + (ny - 1) * var(y)) / (nx + ny - 2))
(mean(x) - mean(y)) / sp
}

```

```

xF16 <- df$IMC[df$Sexo == "Feminino" & df$Semestre == "2016-2"]
xF17 <- df$IMC[df$Sexo == "Feminino" & df$Semestre == "2017-2"]
tF <- t.test(xF16, xF17)
tF

```

```

##
## Welch Two Sample t-test
##
## data: xF16 and xF17
## t = 2.17, df = 8.5966, p-value = 0.0595
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.1318507 5.4075232
## sample estimates:
## mean of x mean of y
## 21.08443 18.44660
dF <- cohend(xF16, xF17)
cat("Cohen's d =", round(dF, 2), "\n")

```

```

## Cohen's d = 1.21

```

```

wF <- wilcox.test(xF16, xF17)
wF

```

```

##
## Wilcoxon rank sum exact test
##
## data: xF16 and xF17
## W = 24, p-value = 0.07273
## alternative hypothesis: true location shift is not equal to 0
xM16 <- df$IMC[df$Sexo == "Masculino" & df$Semestre == "2016-2"]
xM17 <- df$IMC[df$Sexo == "Masculino" & df$Semestre == "2017-2"]
tM <- t.test(xM16, xM17)
tM

```

```

##
## Welch Two Sample t-test
##
## data: xM16 and xM17
## t = 0.53979, df = 38.057, p-value = 0.5925
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -1.788823 3.089716
## sample estimates:
## mean of x mean of y
## 24.93595 24.28551
dM <- cohend(xM16, xM17)
cat("Cohen's d =", round(dM, 2), "\n")

```

```

## Cohen's d = 0.17

```

```
wM <- wilcox.test(xM16, xM17)
wM
```

```
##
## Wilcoxon rank sum exact test
##
## data: xM16 and xM17
## W = 236, p-value = 0.7088
## alternative hypothesis: true location shift is not equal to 0
```

Utilizamos o teste *t* de **Welch** (variâncias não necessariamente iguais) como teste principal em ambos os grupos, por ser mais robusto a diferenças de variância; o teste de Wilcoxon acompanha como checagem de robustez sob não-normalidade. A adequação dessas escolhas é verificada a seguir.

Potência do teste

A potência é calculada abaixo para o δ^* (MCID) fixado a priori na seção de Desenho experimental, independente do que foi observado nos dados.

```
sdF <- sqrt((var(xF16) + var(xF17)) / 2)
sdM <- sqrt((var(xM16) + var(xM17)) / 2)
nF <- mean(c(length(xF16), length(xF17)))
nM <- length(xM16)

potF <- power.t.test(n = nF, delta = mcid, sd = sdF, sig.level = 0.05)
potM <- power.t.test(n = nM, delta = mcid, sd = sdM, sig.level = 0.05)
npotF <- power.t.test(delta = mcid, sd = sdF, sig.level = 0.05, power = 0.80)
npotM <- power.t.test(delta = mcid, sd = sdM, sig.level = 0.05, power = 0.80)

potF; potM; npotF; npotM
```

```
##
## Two-sample t test power calculation
##
## n = 5.5
## delta = 1
## sd = 2.051034
## sig.level = 0.05
## power = 0.1085384
## alternative = two.sided
##
## NOTE: n is number in *each* group

##
## Two-sample t test power calculation
##
## n = 21
## delta = 1
## sd = 3.904637
## sig.level = 0.05
## power = 0.1250999
## alternative = two.sided
##
## NOTE: n is number in *each* group
##
```

```
##      Two-sample t test power calculation
##
##          n = 67.01045
##          delta = 1
##          sd = 2.051034
##          sig.level = 0.05
##          power = 0.8
##          alternative = two.sided
##
## NOTE: n is number in *each* group

##      Two-sample t test power calculation
##
##          n = 240.2951
##          delta = 1
##          sd = 3.904637
##          sig.level = 0.05
##          power = 0.8
##          alternative = two.sided
##
## NOTE: n is number in *each* group
```

Para o grupo **feminino**, a potência para detectar $\delta^* = 1 \text{ kg/m}^2$ é de apenas 10.9%, com $n = 7$ e $n = 4$. Seriam necessárias ≈ 68 observações por semestre para atingir 80% de potência nesse efeito. A não-rejeição de H_0 é, portanto, inconclusiva quanto a um efeito do tamanho do δ^* .

Para o grupo **masculino**, apesar de $n = 21$ em cada semestre, a potência para o mesmo δ^* é de apenas 12.5%. Seriam necessárias ainda cerca de 241 observações por semestre para atingir 80% de potência — bem mais que o exigido no grupo feminino, porque o desvio-padrão do IMC masculino (3.9) é quase o dobro do feminino (2.05). Ou seja, **o $n = 21$ que parecia suficiente no desenho original não basta para detectar o efeito mínimo relevante pré-especificado.**

Verificação das premissas

Ainda que o teste t de Welch seja razoavelmente robusto a pequenos desvios das premissas, verificamos abaixo se a normalidade e a homogeneidade de variância dos dados usados no teste acima são razoáveis.

A Tabela 3 apresenta os resultados do teste de Shapiro-Wilk de normalidade para cada grupo.

```
grupos <- expand.grid(Sexo = levels(df$Sexo), Semestre = levels(df$Semestre))
sw <- apply(grupos, 1, function(g) {
  x <- df$IMC[df$Sexo == g["Sexo"] & df$Semestre == g["Semestre"]]
  s <- shapiro.test(x)
  data.frame(Sexo = g["Sexo"], Semestre = g["Semestre"], n = length(x),
             W = round(s$statistic, 3), p_valor = round(s$p.value, 3))
})
knitr::kable(do.call(rbind, sw), row.names = FALSE,
             caption = "Teste de Shapiro-Wilk por grupo")
```

Tabela 3: Teste de Shapiro-Wilk por grupo

Sexo	Semestre	n	W	p_valor
Feminino	2016-2	7	0.920	0.467
Masculino	2016-2	21	0.928	0.127
Feminino	2017-2	4	0.747	0.037

Sexo	Semestre	n	W	p_valor
Masculino	2017-2	21	0.965	0.621

O único grupo em que a normalidade é rejeitada a 5% é o feminino de 2017-2 ($p = 0.037$), mas com $n = 4$ o teste de Shapiro-Wilk tem potência muito baixa para detectar não-normalidade, então esse resultado precisa ser interpretado com cautela nos dois sentidos: nem confirma nem descarta bem a suposição.

```
fligner.test(IMC ~ Semestre, data = df[df$Sexo == "Feminino", ])

##
## Fligner-Killeen test of homogeneity of variances
##
## data:  IMC by Semestre
## Fligner-Killeen:med chi-squared = 0.71101, df = 1, p-value = 0.3991

fligner.test(IMC ~ Semestre, data = df[df$Sexo == "Masculino", ])

##
## Fligner-Killeen test of homogeneity of variances
##
## data:  IMC by Semestre
## Fligner-Killeen:med chi-squared = 0.082824, df = 1, p-value = 0.7735
```

Nenhum dos testes de Fligner-Killeen rejeita igualdade de variâncias, o que é consistente com a escolha do teste t de Welch já utilizado acima: por ser mais robusto e ter perda de potência pequena quando as variâncias são de fato iguais, essa escolha permanece adequada independentemente do resultado desta checagem. De fato, escolher entre o teste de Student e o de Welch com base no resultado de um teste prévio de igualdade de variâncias é desaconselhado na literatura metodológica, por distorcer a taxa de erro tipo I nominal do teste final [2].

Conclusões e Recomendações

- Ao nível $\alpha = 0.05$, não há evidência estatística de diferença no IMC médio entre 2016-2 e 2017-2, nem para mulheres ($p = 0.06$) nem para homens ($p = 0.592$).
- Para **ambos os grupos**, a potência para detectar o $\delta^* = 1 \text{ kg/m}^2$ é baixa ($\approx 11\%$ nas mulheres, $\approx 13\%$ nos homens): a não-rejeição de H_0 é inconclusiva nos dois casos, não apenas no grupo feminino como o desenho baseado no efeito observado sugeria.
- **Recomendações para melhorar o experimento:** (i) aumentar o tamanho amostral em **ambos os grupos** — não só no feminino — para algo próximo de 68 por semestre nas mulheres e 241 por semestre nos homens, caso o objetivo seja ter potência para detectar o δ^* com esse desenho; dado o custo de coletar ~ 241 homens por semestre, vale reconsiderar se esse é de fato o limiar relevante para decisões práticas neste contexto; (ii) coletar idade (e, se possível, outras covariáveis de estilo de vida) de forma consistente nos dois semestres, já que faltam no arquivo de 2016-2 e são um confundidor plausível; (iii) se o objetivo for medir mudança ao longo do tempo (e não só diferença entre coortes), considerar um desenho pareado/longitudinal com os mesmos indivíduos, em vez de duas amostras independentes; (iv) dado que o IMC é um proxy limitado para composição corporal, complementar com outra métrica (ex. percentual de gordura, relação cintura-quadril) aumentaria a confiabilidade das conclusões.

Referências

- [1] Kral P, Holst-Hansen T, Olivieri AV, Ivanescu C, et al. The Correlation Between Body Mass Index and Health-Related Quality of Life: Data from Two Weight Loss Intervention Studies. *Adv Ther.* 2024;41:4228–4247. <https://doi.org/10.1007/s12325-024-02932-8>
- [2] Steele RG, Gayes LA, Dalton WT, Smith C, Maphis L, Conway-Williams E. Change in health-related quality of life in the context of pediatric obesity interventions: A meta-analytic review. *Health Psychol.*

2016;35(10):1097-1109. <https://doi.org/10.1037/hea0000362>

[3] Hakim Z, Wolf A, Garrison LP. Estimating the effect of changes in body mass index on health state preferences. *Pharmacoeconomics*. 2002;20(6):393-404. <https://doi.org/10.2165/00019053-200220060-00004>

[4] Delacre M, Lakens D, Leys C. Why Psychologists Should by Default Use Welch’s t-test Instead of Student’s t-test. *Int Rev Soc Psychol*. 2017;30(1):92-101. <https://doi.org/10.5334/irsp.82> (ver errata: Delacre M, Lakens D, Leys C. Correction. . . *Int Rev Soc Psychol*. 2022;35(1):21. <https://doi.org/10.5334/irsp.661> — não altera a conclusão principal)

Papéis da equipe

- Amanda Bomfim Moitinho — *Verificadora*
- David Felipe Brochero Giraldo — *Relator*
- Henrique Marques Cruz — *Relator*

Declaração sobre o uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram o assistente de IA Claude (Anthropic) para apoiar a estruturação do código de análise estatística em R e a redação deste relatório. Após o uso dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo do relatório.