

EEE933 - Estudo de Caso 02: Avaliação e comparação do retorno médio de ações

Amanda Bomfim Moitinho, David Felipe Brochero Giraldo, Henrique Marques Cruz

25/09/2026

Resumo

Este estudo avalia qual, dentre cinco ações candidatas, tem maior potencial de retorno mensal para um investidor que pretende aplicar todo o capital em uma única ação. A partir dos preços de fechamento dos últimos 36 meses foram calculados 35 retornos mensais por ação. As médias foram comparadas por Análise de Variância (ANOVA) de um fator, com o teste de Kruskal-Wallis como checagem de robustez, seguida de comparações múltiplas de Tukey. As premissas foram verificadas via Shapiro-Wilk (normalidade), Fligner-Killeen (homogeneidade de variâncias) e Durbin-Watson (autocorrelação serial). A ANOVA rejeitou a igualdade das médias ($p < 0.001$). As ações A1 ($\bar{R} = 2.15\%$ ao mês) e A3 ($\bar{R} = 1.87\%$ ao mês) apresentaram retorno médio significativamente maior que o das demais, mas não diferiram entre si. Na comparação direta entre as duas, a diferença média foi de 0.28 p.p. ao mês a favor da A1 ($p = 0.187$, IC 95%: $[-0.14; 0.7]$), sem diferença detectável de volatilidade, e o teste de equivalência (TOST) com margem $\delta^* = 0.5$ p.p. foi inconclusivo quanto à equivalência. A1 apresentou a maior estimativa pontual de retorno, mas a potência do experimento para detectar δ^* nas comparações entre pares é limitada. Assim, os dados sustentam A1 e A3 como candidatas ao maior retorno médio, mas não fornecem evidência estatística suficiente para separá-las com segurança.

Desenho experimental

Descrição do problema

O objetivo é identificar a ação com maior retorno mensal médio dentre cinco candidatas, usando os retornos dos últimos 35 meses como amostra do comportamento mensal de cada ação. Para cada ação i e mês j , a variável de resposta é o retorno mensal simples, em %:

$$R_{ij} = 100 \left(\frac{P_{ij}}{P_{i,j-1}} - 1 \right),$$

em que P_{ij} é o preço de fechamento da ação i no mês j . Pela simplificação do enunciado, o preço de abertura de um mês é igual ao fechamento do mês anterior, de modo que R_{ij} é exatamente o ganho percentual de quem compra a ação no início do mês j e a vende no fim desse mês. Como as ações podem ser adquiridas de forma fracionária, esse ganho percentual independe do montante investido e do preço unitário de cada ação, o que torna os retornos das cinco ações diretamente comparáveis. Por esse mesmo motivo, os preços em si não são comparáveis entre ações e não foram utilizados como variável de resposta.

A média foi adotada como parâmetro de interesse porque o investidor busca o maior ganho mensal *esperado*. Os retornos das cinco ações foram modelados por um modelo de efeitos fixos de um fator (**Ação**, com $a = 5$ níveis e $n = 35$ observações por nível):

$$R_{ij} = \mu + \tau_i + \epsilon_{ij}, \quad \begin{cases} i = 1, \dots, 5 \\ j = 1, \dots, 35 \end{cases}, \quad \epsilon_{ij} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

em que μ é a média global e τ_i é o efeito da ação i [2]. O modelo de efeitos fixos é apropriado porque as cinco ações foram escolhidas pelo investidor, e as conclusões valem apenas para elas.

Como os cinco retornos de um mesmo mês são observados sob as mesmas condições de mercado, uma alternativa seria tratar o mês como bloco, de modo análogo ao pareamento na comparação de duas amostras. O pareamento, porém, só é vantajoso quando há correlação relevante entre as observações de um mesmo bloco. Essa correlação foi avaliada na Análise Exploratória e, por ser praticamente nula, optou-se pelo modelo de um fator, mais simples e com mais graus de liberdade residuais.

Hipóteses

A pergunta foi respondida em duas etapas, planejadas antes da análise.

Etapla 1 (ANOVA): verifica-se se existe diferença entre os retornos médios das ações:

$$\begin{cases} H_0 : \tau_i = 0, \forall i \in \{1, \dots, 5\} \\ H_1 : \exists \tau_i \neq 0 \end{cases}$$

Etapla 2 (comparações múltiplas): caso H_0 seja rejeitada, é preciso identificar *quais* ações diferem. Como não há uma ação de referência definida a priori (nenhuma das cinco é um “controle”), foram planejadas comparações de todos contra todos pelo método de Tukey [2, 6], com $K = a(a - 1)/2 = 10$ pares:

$$\begin{cases} H_0 : \mu_i = \mu_k \\ H_1 : \mu_i \neq \mu_k \end{cases} \quad \forall i < k.$$

O método de Dunnett seria apropriado se uma ação de referência tivesse sido definida antes da coleta. Como não há uma ação-controle definida a priori, o método de Tukey permite comparar todos os pares mantendo o nível global de significância. As ações que não diferirem significativamente da ação de maior média amostral formam o grupo de candidatas ao maior retorno.

Evidências complementares: se mais de uma ação se destacar, conforme solicitado no enunciado, as duas primeiras colocadas serão comparadas diretamente por (i) teste t pareado das diferenças mensais, (ii) teste de equivalência por dois testes unilaterais (TOST) com margem δ^* [4], (iii) comparação das variâncias (volatilidade) pelo teste de Fligner-Killeen e (iv) frequência de meses com retorno negativo. O pareamento é natural nessa comparação, pois as duas ações são observadas nos mesmos 35 meses. Embora esse procedimento tenha sido definido antes da análise, as ações comparadas são escolhidas por terem as maiores médias amostrais, de modo que a diferença observada entre elas tende a estar superestimada; os resultados dessa etapa são, por isso, tratados como evidência complementar, e não como prova de superioridade.

O nível de significância adotado é $\alpha = 0.05$ em todas as etapas, e a potência desejada é $1 - \beta = 0.8$.

Tamanho de efeito mínimo relevante (δ^*)

Não há um valor consensual de diferença de retorno mensal a partir da qual uma ação deva ser preferida a outra, pois esse limiar depende do perfil do investidor, dos custos de transação e dos impostos. Definiu-se $\delta^* = 0.5$ ponto percentual ao mês, o que, para ações com retorno próximo de 2% ao mês, corresponde a uma diferença de ≈ 7.3 p.p. no retorno anual composto, diferença que altera de forma perceptível o resultado de uma aplicação ao longo de um ano. Diferenças menores que essa foram consideradas pouco relevantes para a decisão, pois tendem a ser absorvidas pelos custos de transação e impostos desconsiderados nas simplificações do problema. Ressalva-se que esse valor é uma escolha da equipe, usada para ancorar a análise de potência e o teste de equivalência, e não um valor extraído da literatura.

```
delta_star <- 0.5 # delta* adotado, em p.p. ao mês
```

Descrição da coleta e consolidação dos dados

O arquivo `DadosAcoesGrupoA.csv` contém 36 linhas e 5 colunas, sem cabeçalho, com os preços de fechamento mensais de cada ação (colunas), ordenados **do mês mais recente para o mais antigo** (linha 1 = mês anterior ao atual). As colunas foram nomeadas A1 a A5, na ordem em que aparecem no arquivo.

Inversão da série: como o retorno de um mês depende do preço do mês anterior, a série foi invertida para a ordem cronológica antes do cálculo. Sem essa inversão, os retornos seriam calculados no sentido oposto e uma ação em alta pareceria estar em queda. Com 36 preços obtêm-se $n = 35$ retornos por ação.

Suposições explícitas: (i) conforme o enunciado, o preço de abertura de cada mês é igual ao fechamento do mês anterior e as ações podem ser adquiridas de forma fracionária; (ii) os preços fornecidos não incluem dividendos, desdobramentos ou custos de transação, de modo que os retornos calculados são retornos brutos de preço.

Análise Exploratória

Os dados foram carregados e consolidados conforme descrito no Desenho experimental:

```
precos <- read.csv("DadosAcoesGrupoA.csv", header = FALSE)
names(precos) <- paste0("A", 1:ncol(precos))

# Arquivo ordenado do mês mais recente para o mais antigo: inverter
precos <- precos[nrow(precos):1, ]
P <- as.matrix(precos)

# Retornos mensais simples (%)
ret <- 100 * (P[-1, ] / P[-nrow(P), ] - 1)
n <- nrow(ret)

df <- data.frame(
  Mes = rep(1:n, times = ncol(ret)),
  Acao = factor(rep(colnames(ret), each = n)),
  Ret = as.vector(ret)
)
```

A Tabela 1 resume as estatísticas descritivas dos retornos mensais por ação.

Tabela 1: Estatísticas descritivas dos retornos mensais (%) por ação

Acao	Media	DP	Mediana	Min	Max	MesesNeg
A1	2.147	0.871	2.243	-0.547	3.881	1
A2	-0.464	1.116	-0.445	-2.238	1.486	23
A3	1.869	0.803	2.036	-0.274	3.399	1
A4	0.359	1.174	0.309	-1.923	3.301	15
A5	0.196	1.053	0.213	-2.112	2.332	13

A Figura 1 mostra a evolução dos preços normalizados pelo primeiro mês da série, e a Figura 2 ilustra a distribuição dos retornos mensais por ação.

```
Pn <- sweep(P, 2, P[1, ], "/" ) * 100
dfP <- data.frame(Mes = rep(0:n, times = ncol(P)),
  Acao = rep(colnames(P), each = n + 1),
  Preco = as.vector(Pn))
ggplot(dfP, aes(x = Mes, y = Preco, colour = Acao)) +
```

```
geom_line(linewidth = 0.8) +
labs(x = "Mês", y = "Preço normalizado", colour = "Ação") +
theme_minimal()
```




Figura 1: Preços de fechamento normalizados pelo primeiro mês da série (base 100)

```
ggplot(df, aes(x = Acao, y = Ret, fill = Acao)) +
  geom_boxplot(alpha = 0.6, outlier.shape = NA) +
  geom_jitter(width = 0.1, alpha = 0.6) +
  stat_summary(fun = mean, geom = "point", colour = "red", size = 3) +
  geom_hline(yintercept = 0, linetype = 2) +
  labs(y = "Retorno mensal (%)", x = NULL) +
  theme_minimal() +
  theme(legend.position = "none")
```

Duas ações, A1 e A3, apresentam tendência de alta consistente, com retornos médios próximos de 2% ao mês e apenas 1 e 1 mês(es) de retorno negativo em 35, respectivamente. A A2 tem média negativa, enquanto A4 e A5 oscilam em torno de zero. As dispersões são da mesma ordem de grandeza (desvios-padrão entre 0.8 e 1.17 p.p.), e os boxplots são aproximadamente simétricos, sem *outliers* evidentes.

A Tabela 2 apresenta a correlação entre os retornos mensais das ações, que indica se o pareamento por mês seria vantajoso.

Tabela 2: Correlação entre os retornos mensais das ações

	A1	A2	A3	A4	A5
A1	1.00	0.01	-0.06	0.07	-0.08
A2	0.01	1.00	-0.06	-0.10	0.16
A3	-0.06	-0.06	1.00	0.06	0.09
A4	0.07	-0.10	0.06	1.00	-0.05
A5	-0.08	0.16	0.09	-0.05	1.00

As correlações são baixas (em módulo, no máximo 0.16), ou seja, as ações não respondem de forma comum a




Figura 2: Retornos mensais por ação (pontos vermelhos: médias)

um “efeito de mercado” mensal. O mês, portanto, não é uma fonte relevante de variabilidade compartilhada, e tratá-lo como bloco não reduziria a variância residual. Isso justifica o uso do modelo de um fator definido no Desenho experimental.

Análise Estatística

Etapa 1: ANOVA

```
modelo <- aov(Ret ~ Acao, data = df)
summary(modelo)
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Acao          4  178.9   44.73   43.54 <2e-16 ***
## Residuals    170  174.7    1.03
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Checagem de robustez: alternativa não paramétrica à ANOVA

```
kruskal.test(Ret ~ Acao, data = df)
```

```
##
## Kruskal-Wallis rank sum test
##
## data: Ret by Acao
## Kruskal-Wallis chi-squared = 92.902, df = 4, p-value < 2.2e-16
```

A hipótese nula de que todas as ações têm o mesmo retorno médio é rejeitada ($F = 43.54$, $p < 0.001$), conclusão corroborada pelo teste de Kruskal-Wallis, que não depende da premissa de normalidade (embora teste diferenças de distribuição, e não especificamente de médias). Há, portanto, ao menos uma ação com retorno médio diferente das demais.

Etapa 2: comparações múltiplas de Tukey

```
tuk <- glht(modelo, linfct = mcp(Acao = "Tukey"))
tuk_CI <- confint(tuk, level = 0.95)
tuk_CI

##
## Simultaneous Confidence Intervals
##
## Multiple Comparisons of Means: Tukey Contrasts
##
##
## Fit: aov(formula = Ret ~ Acao, data = df)
##
## Quantile = 2.7582
## 95% family-wise confidence level
##
## Linear Hypotheses:
##           Estimate   lwr      upr
## A2 - A1 == 0 -2.611021 -3.279329 -1.942712
## A3 - A1 == 0 -0.277662 -0.945970  0.390647
## A4 - A1 == 0 -1.787909 -2.456217 -1.119600
## A5 - A1 == 0 -1.950474 -2.618782 -1.282165
## A3 - A2 == 0  2.333359  1.665051  3.001668
## A4 - A2 == 0  0.823112  0.154803  1.491421
## A5 - A2 == 0  0.660547 -0.007761  1.328856
## A4 - A3 == 0 -1.510247 -2.178556 -0.841939
## A5 - A3 == 0 -1.672812 -2.341121 -1.004503
## A5 - A4 == 0 -0.162565 -0.830873  0.505744

par(mar = c(4, 8, 2, 1))
plot(tuk_CI, main = "", xlab = "Diferença de retorno médio (p.p./mês)")
```

A ação de maior média amostral é a A1. O único intervalo de confiança envolvendo a A1 que contém o zero é o da diferença A3 – A1, ou seja, apenas a A3 não difere significativamente dela. Além disso, tanto a A1 quanto a A3 têm retorno médio significativamente maior que o de todas as demais ações, com diferenças entre 1.5 e 2.6 p.p. ao mês. As ações **A1** e **A3** se destacam, portanto, como candidatas ao maior retorno médio. Entre as demais, apenas a diferença A4 – A2 é significativa (a diferença A5 – A2 fica no limiar, com limite inferior do IC muito próximo de zero), o que não afeta a decisão.

Verificação das premissas

O modelo da ANOVA pressupõe resíduos (1) independentes, (2) com variância homogênea entre as ações e (3) normalmente distribuídos. Embora a ANOVA seja relativamente robusta a violações moderadas de normalidade e de homocedasticidade quando o delineamento é balanceado [2], como neste caso (35 observações por ação), essas premissas foram verificadas.

```
par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
qqPlot(modelo$residuals, pch = 16, las = 1, id = FALSE,
        xlab = "Quantis da Normal", ylab = "Resíduos")
plot(modelo$fitted.values, modelo$residuals, pch = 16, las = 1,
      xlab = "Valores ajustados", ylab = "Resíduos")
abline(h = 0, lty = 2)
```




Figura 3: Intervalos de confiança simultâneos de 95% (Tukey) para as diferenças entre médias




Figura 4: Gráfico quantil-quantil dos resíduos (esquerda) e resíduos em função dos valores ajustados (direita)

```
shapiro.test(modelo$residuals)

##
## Shapiro-Wilk normality test
##
## data:  modelo$residuals
## W = 0.9965, p-value = 0.96

fligner.test(Ret ~ Acao, data = df)

##
## Fligner-Killeen test of homogeneity of variances
##
## data:  Ret by Acao
## Fligner-Killeen:med chi-squared = 7.7931, df = 4, p-value = 0.09946
```

Normalidade. Os resíduos não apresentam desvio relevante da normalidade (Shapiro-Wilk, $p = 0.96$), e os pontos do gráfico quantil-quantil permanecem dentro da banda de confiança.

Homocedasticidade. O teste de Fligner-Killeen não rejeita a igualdade de variâncias entre as ações ($p = 0.099$), e o gráfico de resíduos por valores ajustados mostra dispersões semelhantes nos cinco níveis. O p -valor não é muito distante de α , mas as razões entre os desvios-padrão das ações são pequenas (no máximo ≈ 1.46), e o delineamento balanceado torna a ANOVA robusta a diferenças dessa magnitude. A premissa é consistente com os dados e justifica o uso de uma variância comum σ^2 , estimada pelo QM_{Res} , na ANOVA, nas comparações de Tukey e no cálculo de potência.

Independência. É a premissa mais delicada, pois os dados são séries temporais, e retornos de meses consecutivos poderiam estar correlacionados (por exemplo, por tendências de mercado). O teste de Durbin-Watson [7] depende da ordenação das observações, e por isso foi aplicado a cada série de retornos em ordem cronológica, que é o fator suspeito de introduzir dependência.

```
set.seed(2026) # o p-valor do durbinWatsonTest é obtido por reamostragem
dw <- t(sapply(colnames(ret), function(a) {
  r <- durbinWatsonTest(lm(ret[, a] ~ 1))
  c(Autocorrelacao = r$r, DW = r$dw, p_valor = r$p)
}))
knitr::kable(dw, digits = 3,
              caption = "Teste de Durbin-Watson para cada série de retornos")
```

Tabela 3: Teste de Durbin-Watson para cada série de retornos

	Autocorrelacao	DW	p_valor
A1	0.005	1.976	0.968
A2	0.088	1.747	0.460
A3	-0.123	2.222	0.514
A4	-0.188	2.357	0.264
A5	-0.054	2.043	0.856

Nenhuma série apresenta autocorrelação de primeira ordem significativa (todos os p -valores acima de 0.05), e as estatísticas DW estão próximas de 2, valor esperado na ausência de autocorrelação. A dependência entre ações num mesmo mês também é desprezível, como mostrado na Tabela 2. Não há, portanto, evidência de violação da independência.

Resta uma premissa mais forte e não verificável com estes dados: a de que o comportamento dos retornos é estável no tempo, isto é, de que a média dos últimos 35 meses representa o retorno esperado para o próximo mês. Os testes comparam médias *históricas*, e a recomendação para o mês seguinte depende dessa hipótese.

Evidências complementares para a escolha entre A1 e A3

Como duas ações se destacaram, elas foram comparadas diretamente. Por serem observadas nos mesmos meses, a comparação foi feita com as diferenças pareadas $D_j = R_{A1,j} - R_{A3,j}$, pelo teste t pareado [1].

```
x <- ret[, melhor]; y <- ret[, segunda]; d <- x - y

# (i) Teste t pareado (bilateral) e tamanho de efeito
tD <- t.test(x, y, paired = TRUE)
tD

##
## Paired t-test
##
## data: x and y
## t = 1.3452, df = 34, p-value = 0.1875
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## -0.1418103 0.6971334
## sample estimates:
## mean difference
## 0.2776616

dD <- mean(d) / sd(d)
cat("Tamanho de efeito d =", round(dD, 2), "\n")

## Tamanho de efeito d = 0.23

# (ii) TOST:  $H_0: |\mu_D| \geq \delta$  vs  $H_1: |\mu_D| < \delta$ 
p_inf <- t.test(d, mu = -delta_star, alternative = "greater")$p.value
p_sup <- t.test(d, mu = delta_star, alternative = "less")$p.value
ic90 <- t.test(d, conf.level = 0.90)$conf.int
c(p_inferior = p_inf, p_superior = p_sup)

## p_inferior p_superior
## 0.0003134829 0.1444921545

ic90

## [1] -0.07135899 0.62668212
## attr("conf.level")
## [1] 0.9

# (iii) Comparação das variâncias (volatilidade)
fk <- fligner.test(list(x, y))
fk

##
## Fligner-Killeen test of homogeneity of variances
##
## data: list(x, y)
## Fligner-Killeen:med chi-squared = 0.046521, df = 1, p-value = 0.8292

# Premissa de normalidade das diferenças pareadas (teste t pareado e TOST)
shapiro.test(d)

##
## Shapiro-Wilk normality test
##
```

```
## data: d
## W = 0.9734, p-value = 0.543
```

Tabela 4: Comparação entre A1 e A3

Acao	Media	DP	Media_DP	MesesNeg
A1	2.147	0.871	2.465	1
A3	1.869	0.803	2.327	1

(i) **Diferença de médias.** A diferença média estimada é de 0.28 p.p. ao mês a favor da A1, com tamanho de efeito pequeno ($d = 0.23$), e o teste t pareado não a considera significativa ($p = 0.187$; IC 95%: $[-0.14; 0.7]$). O resultado é consistente com o obtido pelo método de Tukey. As diferenças pareadas não apresentam desvio relevante da normalidade (Shapiro-Wilk, $p = 0.543$), premissa do teste t pareado e do TOST.

(ii) **Equivalência.** A não rejeição em (i) não permite afirmar que as ações são equivalentes, e por isso foi realizado o TOST. O teste inferior rejeita sua hipótese nula ($p = 3.1 \times 10^{-4}$), fornecendo evidência de que a diferença média não é menor ou igual a $-\delta^*$. Já o teste superior não rejeita sua hipótese nula ($p = 0.144$). De forma equivalente, o IC de 90% $[-0.07; 0.63]$ não está contido em $[-\delta^*; \delta^*]$. Portanto, os dados sustentam não-inferioridade de A1 em relação a A3 para a margem de 0,5 p.p., mas **não sustentam equivalência** entre as duas ações. Como o intervalo ainda inclui diferenças positivas de até aproximadamente 0.6 p.p. ao mês, não é possível determinar, com este experimento, se a diferença real é pequena ou se A1 apresenta alguma vantagem dentro dessa margem.

(iii) **Risco.** Como o investidor aplica todo o capital em uma única ação, a volatilidade também é relevante para a decisão. O teste de Fligner-Killeen não indica diferença entre as variâncias das duas ações ($p = 0.829$), e as razões média/desvio-padrão são muito próximas (Tabela 4). O teste ignora o pareamento, o que é aceitável aqui dada a correlação praticamente nula entre as duas séries (Tabela 2).

(iv) **Meses com perda.** As duas ações tiveram retorno negativo em apenas 1 e 1 dos 35 meses, respectivamente, de modo que esse critério também não as distingue.

Potência do teste

A potência foi calculada para o δ^* definido a priori, e não a partir do efeito observado, pois a avaliação a posteriori da probabilidade do erro tipo II é uma abordagem inadequada [8]. O desvio-padrão comum foi estimado pela raiz do quadrado médio do resíduo da ANOVA, $\hat{\sigma} = \sqrt{QM_{Res}} = 1.014$ p.p.

Foram realizados três cálculos [3]. O primeiro refere-se à ANOVA, considerando o cenário conservador em que apenas duas ações diferem por δ^* , com desvios simétricos em relação à média global e as demais sem efeito, $\tau = \{-\delta^*/2, \delta^*/2, 0, 0, 0\}$. O segundo refere-se às comparações entre pares, usando a correção de Bonferroni ($\alpha_{aj} = \alpha/K$, com $K = 10$) e a fórmula do teste t de duas amostras. Como a correção de Bonferroni é mais conservadora que o método de Tukey, esse cálculo fornece uma referência conservadora para a potência das comparações. O terceiro refere-se à comparação direta entre as duas ações de destaque pelo teste t pareado ($\alpha = 0.05$), usando o desvio-padrão amostral das diferenças pareadas.

```
sigma <- sqrt(QMR)
tau <- c(-delta_star/2, delta_star/2, 0, 0, 0)
K <- 10

# ANOVA
potA <- power.anova.test(groups = 5, n = n, between.var = var(tau),
                          within.var = sigma^2, sig.level = 0.05)
npotA <- power.anova.test(groups = 5, between.var = var(tau),
                          within.var = sigma^2, sig.level = 0.05, power = 0.80)
```

```

# Comparações entre pares (Bonferroni)
potC <- power.t.test(n = n, delta = delta_star, sd = sigma,
                     sig.level = 0.05 / K, type = "two.sample")
npotC <- power.t.test(delta = delta_star, sd = sigma, sig.level = 0.05 / K,
                     power = 0.80, type = "two.sample")

# Comparação direta entre as duas ações de destaque (t pareado)
potP <- power.t.test(n = n, delta = delta_star, sd = sd(d),
                     sig.level = 0.05, type = "paired")
npotP <- power.t.test(delta = delta_star, sd = sd(d),
                     sig.level = 0.05, power = 0.80, type = "paired")

potA; npotA; potC; npotC; potP; npotP

```

```

##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 5
##      n = 35
##      between.var = 0.03125
##      within.var = 1.027399
##      sig.level = 0.05
##      power = 0.3309148
##
## NOTE: n is number in each group

##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 5
##      n = 99.05183
##      between.var = 0.03125
##      within.var = 1.027399
##      sig.level = 0.05
##      power = 0.8
##
## NOTE: n is number in each group

##
##      Two-sample t test power calculation
##
##      n = 35
##      delta = 0.5
##      sd = 1.013607
##      sig.level = 0.005
##      power = 0.211035
##      alternative = two.sided
##
## NOTE: n is number in *each* group

##
##      Two-sample t test power calculation
##
##      n = 111.4012
##      delta = 0.5

```

```

##          sd = 1.013607
##      sig.level = 0.005
##          power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group

##
##      Paired t test power calculation
##
##          n = 35
##          delta = 0.5
##          sd = 1.221127
##      sig.level = 0.05
##          power = 0.6530544
##      alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs

##
##      Paired t test power calculation
##
##          n = 48.77107
##          delta = 0.5
##          sd = 1.221127
##      sig.level = 0.05
##          power = 0.8
##      alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs

```

Com $n = 35$ meses, a potência da ANOVA para detectar uma diferença de $\delta^* = 0.5$ p.p. entre duas ações é de apenas 33.1%, e seriam necessários 100 meses por ação para atingir 80%. Nas comparações entre pares, a potência é de $\approx 21.1\%$, e seriam necessários cerca de 112 meses. A comparação direta entre A1 e A3 pelo teste t pareado ($\hat{\sigma}_D = 1.221$ p.p.) tem potência de 65.3% para δ^* , abaixo dos 80% desejados, que exigiriam 49 meses. Como a diferença observada (0.28 p.p.) é ainda menor que δ^* , a não rejeição de $\mu_{A1} = \mu_{A3}$ reflete essa limitação e não é evidência de igualdade, o que é coerente com o resultado inconclusivo do TOST.

Em contraste, as diferenças entre as duas ações de destaque e as demais (aproximadamente 1,5 a 2,6 p.p.) são três a cinco vezes maiores que δ^* . Essas diferenças foram identificadas pelas comparações múltiplas de Tukey, que rejeitaram as respectivas hipóteses de igualdade. Assim, os dados fornecem evidência consistente para separar A1 e A3 do grupo formado por A2, A4 e A5.

Conclusões e Recomendações

- Ao nível $\alpha = 0.05$, há forte evidência de que os retornos médios das cinco ações diferem ($p < 0.001$). As ações **A1** e **A3** têm retorno médio significativamente maior que o de A2, A4 e A5, que podem ser descartadas, mas não diferem significativamente entre si.
- Na comparação direta entre A1 e A3: (i) a A1 tem retorno médio 0.28 p.p. ao mês maior (≈ 4.1 p.p. ao ano em regime composto), mas a diferença não é estatisticamente significativa ($p = 0.187$); (ii) o TOST não demonstra equivalência, embora o teste unilateral correspondente forneça evidência de que A1 não seja inferior a A3 por mais de $\delta^* = 0.5$ p.p.; (iii) as volatilidades não diferem significativamente ($p = 0.829$); (iv) ambas tiveram retorno negativo em apenas 1 e 1 dos 35 meses, respectivamente.
- **Implicação para a escolha:** A1 apresenta a maior média amostral e A3 apresenta a segunda maior, mas a diferença de 0.28 p.p. ao mês não foi detectada como significativa pelo teste pareado nem pelo Tukey. Portanto, os dados não permitem selecionar estatisticamente uma única entre A1 e

A3 com base apenas no retorno médio. Se o investidor for obrigado a escolher uma única ação, A1 seria a escolha baseada exclusivamente na maior estimativa pontual observada, mas essa escolha é descritiva e não representa uma demonstração estatística de superioridade. O retorno de um mês específico apresenta desvio-padrão de aproximadamente 0.9 p.p. para A1, valor maior que a diferença média observada entre as duas.

- **Recomendações para melhorar o experimento:** (i) aumentar o número de meses observados para cerca de 112, caso se deseje 80% de potência nas comparações entre pares para δ^* ; séries mais longas, contudo, tornam mais forte a hipótese de estabilidade dos retornos no tempo, e os dois objetivos precisam ser equilibrados; (ii) definir a priori, junto com o investidor, a margem δ^* e um critério de decisão que combine retorno e risco, em vez de usar o risco apenas como critério de desempate; (iii) utilizar preços ajustados por dividendos e desdobramentos e descontar custos de transação e impostos, que podem ser da mesma ordem da diferença entre as duas melhores ações; (iv) validar a recomendação fora da amostra, por exemplo escolhendo a ação com os meses $1, \dots, t$ e verificando seu retorno no mês $t + 1$, o que testa diretamente a pergunta sobre o *próximo* mês; (v) caso uma série mais longa revele correlação entre as ações num mesmo mês, tratar o mês como bloco para remover essa fonte de variabilidade.

Referências

- [1] Montgomery DC, Runger GC. Applied Statistics and Probability for Engineers. 5th ed. Hoboken: John Wiley & Sons; 2010.
- [2] Montgomery DC. Design and Analysis of Experiments. 6th ed. Hoboken: John Wiley & Sons; 2005.
- [3] Mathews P. Sample Size Calculations: Practical Methods for Engineers and Scientists. Fairport Harbor: MMB; 2010.
- [4] Walker E, Nowacki AS. Understanding Equivalence and Noninferiority Testing. J Gen Intern Med. 2011;26(2):192-196.
- [5] Kerr NL. HARKing: Hypothesizing After the Results are Known. Pers Soc Psychol Rev. 1998;2(3):196-217.
- [6] Hothorn T, Bretz F, Westfall P. Simultaneous Inference in General Parametric Models. Biom J. 2008;50(3):346-363.
- [7] Campelo F. Lecture Notes on Design and Analysis of Experiments. Version 2.12; 2018. Disponível em: <http://git.io/v3Kh8>.
- [8] Hoenig JM, Heisey DM. The Abuse of Power: The Pervasive Fallacy of Power Calculations for Data Analysis. Am Stat. 2001;55(1):19-24.

Papéis da equipe

- Amanda Bomfim Moitinho: [PREENCHER]
- David Felipe Brochero Giraldo: [PREENCHER]
- Henrique Marques Cruz: [PREENCHER]

Declaração sobre o uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram o assistente de IA Claude (Anthropic) para apoiar a estruturação do código de análise estatística em R e a revisão do texto e da análise. Após o uso dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo do relatório.