EEE933 - Estudo de Caso 03: Comparação de desempenho de duas configurações de um algoritmo de otimização

Amanda Bomfim Moitinho, David Felipe Brochero Giraldo, Henrique Marques Cruz

02/11/2026

Resumo

Este estudo compara o desempenho médio de duas configurações do algoritmo de evolução diferencial (DE), que diferem nos operadores de mutação e de recombinação, na classe de funções de Rosenbrock de dimensão entre 2 e 150. Foram utilizadas 34 instâncias da classe, quantidade calculada para potência de 80% na detecção de um efeito padronizado $d^* = 0.5$ ao nível $\alpha = 0.05$, e cada configuração foi executada 50 vezes em cada instância. Tratando as instâncias como blocos, as configurações foram comparadas pelo teste t pareado sobre as diferenças entre as médias do melhor valor da função objetivo (Fbest) obtidas por elas em cada instância. O teste rejeitou a igualdade de desempenho médio ($p = 1.34 \times 10^{-8}$), conclusão verificada também pelo teste do sinal ($p = 1.16 \times 10^{-10}$), dado que o teste de Shapiro-Wilk rejeitou a normalidade das diferenças. A Config1 obteve menor valor médio em 34 das 34 instâncias, com diferença média estimada de -4.83×10^6 na escala da função objetivo (IC 95%: $[-6.14 \times 10^6; -3.51 \times 10^6]$) e efeito padronizado $\hat{d} = -1.28$. Recomenda-se, portanto, a Config1 para a classe de problemas avaliada.

Introdução

Muitos problemas de engenharia podem ser formulados como a busca do mínimo (ou máximo) de uma função objetivo, frequentemente não convexa, de muitas variáveis e sem solução analítica. Para esses problemas, algoritmos baseados em populações, como a evolução diferencial (DE, do inglês *differential evolution*) (Storn e Price 1997), são uma alternativa comum: um conjunto de soluções candidatas é repetidamente submetido a operadores de mutação, recombinação e seleção, explorando o espaço de busca. O desempenho do DE, contudo, depende fortemente da configuração adotada, isto é, de quais operadores de mutação e de recombinação são utilizados e de seus parâmetros (Campelo e Botelho 2016).

A escolha da configuração não pode ser feita de forma universal, tendo em vista que não existe algoritmo de otimização superior a todos os demais em todos os problemas possíveis (Wolpert e Macready 1997), de modo que a comparação só faz sentido para uma classe de problemas de interesse. Além disso, o DE é estocástico, e seu resultado varia entre execuções na mesma instância e entre instâncias de uma mesma classe. Comparar configurações com base em poucas execuções ou em uma única instância pode, portanto, levar a conclusões que refletem apenas essa variabilidade. Para que a recomendação de uma configuração seja confiável, a comparação deve ser planejada como um experimento, com número de instâncias e de repetições definido antes da coleta e com controle das probabilidades de erro dos tipos I e II (Campelo e Takahashi 2019).

Neste trabalho, são comparadas duas configurações do DE, previamente ajustadas, na classe de funções de Rosenbrock (Rosenbrock 1960; Bossek 2017) de dimensão entre 2 e 150. A Config1 combina mutação *rand* ($F = 4$) e recombinação aritmética; a Config2 combina mutação *best* ($F = 3$) e recombinação binomial ($CR = 0.7$). A função de Rosenbrock possui um único mínimo global, de valor zero, situado no fundo de um vale estreito e curvo, o que dificulta a convergência de métodos de busca. O desempenho de cada configuração é medido pelo melhor valor da função objetivo ao final da execução, e quanto menor esse valor, melhor a configuração. Busca-se responder às seguintes perguntas:

1. Há diferença no desempenho médio do algoritmo com as duas configurações, para a classe de problemas

de interesse?
2. Caso haja, qual configuração apresenta melhor desempenho médio, e qual é a magnitude da diferença?
3. Alguma configuração deve ser recomendada em relação à outra?

Para isso, as instâncias são tratadas como blocos, de modo que as duas configurações são avaliadas nas mesmas instâncias e a variabilidade entre instâncias é removida da comparação. O número de instâncias é calculado para atingir a potência desejada, as dimensões são distribuídas ao longo do intervalo de interesse, e as configurações são comparadas pelo teste t pareado, com estimativa da magnitude da diferença por intervalo de confiança. Caso a premissa de normalidade das diferenças não seja atendida, a conclusão é verificada por um teste não paramétrico, o teste do sinal.

Desenho experimental

Descrição do problema

Seja Y_{ijk} o melhor valor da função objetivo obtido pela configuração $i \in \{1, 2\}$ na k-ésima execução ($k = 1, \ldots, r$) sobre a instância j ($j = 1, \ldots, N$). Como a função de Rosenbrock é definida sobre variáveis adimensionais, Y_{ijk} e as diferenças D_j também são adimensionais. O desempenho da configuração i na instância j é resumido pela média das r execuções, $\bar{Y}_{ij} = \frac{1}{r}\sum_{k=1}^{r} Y_{ijk}$, e a variável de resposta da comparação é a diferença

$$D_j = \bar{Y}_{1j} - \bar{Y}_{2j}, \qquad j = 1, \ldots, N.$$

Valores negativos de D_j indicam melhor desempenho da Config1. Cada instância é um bloco, e as médias por instância seguem o modelo aditivo

$$\bar{Y}_{ij} = \mu + \tau_i + \beta_j + \epsilon_{ij},$$

em que μ é a média global, τ_i é o efeito da configuração i, β_j é o efeito da instância j e ϵ_{ij} é o resíduo. Na diferença entre as configurações, o efeito da instância se cancela:

$$D_j = (\tau_1 - \tau_2) + (\epsilon_{1j} - \epsilon_{2j}) = \mu_D + \epsilon_j, \qquad \epsilon_j \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_D^2),$$

em que μ_D é a diferença média de desempenho na classe de problemas (Campelo 2018).

Hipóteses

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$

O nível de significância adotado é $\alpha = 0.05$, e a potência desejada para $d = d^*$ é $1 - \beta = 0.8$.

Tamanho de efeito mínimo relevante

O enunciado fixa a mínima diferença de importância prática em unidades do desvio-padrão das diferenças, $d^* = \delta^*/\sigma_D = 0.5$. Como não há estimativa prévia de σ_D, o efeito é especificado na escala padronizada, e o valor de δ^* na escala de Y fica implicitamente definido pela variabilidade das diferenças.

Cálculo do tamanho amostral

Número de instâncias. O número de blocos foi calculado para o teste t pareado bilateral, com $d^* = 0.5$, $\alpha = 0.05$ e potência de 0.8 (Mathews 2010):

```r
# Parâmetros experimentais dados no enunciado
alfa     <- 0.05   # nível de significância
d_star   <- 0.5    # mínima diferença de importância prática (padronizada)
potencia <- 0.80   # potência desejada para d = d*

# Número de instâncias (blocos): teste t pareado bilateral. Como d* já é
# padronizado (d* = delta*/sigma_D), usa-se sd = 1 e delta = d*.
plan <- power.t.test(power = potencia, delta = d_star, sd = 1,
                     sig.level = alfa, alternative = "two.sided",
                     type = "paired")
N <- ceiling(plan$n)

# Potência obtida com o número inteiro de instâncias
pot_N <- power.t.test(n = N, delta = d_star, sd = 1, sig.level = alfa,
                      type = "paired")$power

# Dimensões: grade uniformemente espaçada em [2, 150], arredondada
dims <- round(seq(2, 150, length.out = N))

# Repetições de cada configuração por instância
n_reps <- 50
```

```r
plan
```

```
##
##      Paired t test power calculation
##
##               n = 33.3672
##           delta = 0.5
##              sd = 1
##       sig.level = 0.05
##           power = 0.8
##     alternative = two.sided
##
## NOTE: n is number of *pairs*, sd is std.dev. of *differences* within pairs
```

```r
dims
```

```
##  [1]   2   6  11  15  20  24  29  33  38  42  47  51  56  60  65  69  74  78  83
## [20]  87  92  96 101 105 110 114 119 123 128 132 137 141 146 150
```

Assim, são necessárias $N = 34$ instâncias ($n = 33.37$, arredondado para cima). Com isso, a potência do teste para $d = d^*$ é de 80.8%, o que atende ao requisito do enunciado.

As dimensões foram distribuídas em uma grade uniformemente espaçada no intervalo $[2, 150]$, arredondada para inteiros. Essa amostragem sistemática garante que toda a faixa de dimensões da classe seja coberta com a mesma densidade.

Repetições por instância. O número de instâncias e o número de repetições por instância são determinados de forma independente (Campelo e Takahashi 2019). O teste é feito sobre as médias por instância, de modo que o número de repetições r não altera os graus de liberdade do teste, mas determina o erro-padrão da estimativa D_j em cada instância. Supondo execuções independentes e as condições do Teorema Central do Limite, esse erro-padrão é

$$se_j = \sqrt{\frac{s_{1j}^2}{r} + \frac{s_{2j}^2}{r}},$$

em que s_{ij}^2 é a variância amostral das r execuções da configuração i na instância j. A variância total das diferenças é a soma da variância entre instâncias, que não pode ser controlada, com essa parcela devida à aleatoriedade das execuções. Para que o ruído de cada execução não reduza a potência planejada, adotou-se como critério prático, inspirado no limiar de acurácia se^* proposto por Campelo e Takahashi (2019), que $se_j^2 \leq 0.1\,\sigma_D^2$ em cada instância, de modo que a inflação da variância das diferenças devida ao ruído das execuções fique abaixo de 10%.

Campelo e Takahashi (2019) propõem determinar o número de execuções de cada configuração iterativamente em cada instância, aumentando-o até que se_j fique abaixo de um limiar se^*; para classes com instâncias de escalas muito diferentes, como a deste estudo, os autores recomendam aplicar o procedimento à diferença percentual entre as médias. Os mesmos autores admitem o uso parcial da metodologia, por exemplo com um número predefinido de repetições. Neste estudo, adotou-se um número fixo de $r = 50$ repetições por configuração em todas as instâncias, superior ao tamanho amostral inicial recomendado por esses autores para distribuições fortemente assimétricas (20 a 30 execuções), uma vez que a forma da distribuição de Y não era conhecida antes da coleta. Como esse valor não decorre do procedimento iterativo, o atendimento do critério $se_j^2 \leq 0.1\,\sigma_D^2$ é verificado a posteriori na Análise Estatística.

Descrição da coleta dos dados

O arquivo `DadosDEGrupoA_bruto.csv` contém uma linha por execução (3400 linhas, com as colunas `dimensao`, `instancia`, `repeticao`, `configuracao` e `Fbest`).

Esses dados foram gerados com os pacotes `ExpDE` e `smoof`, com os parâmetros fixados no enunciado. Cada execução utiliza uma semente própria, definida a partir de uma semente base, do índice da instância, da repetição e da configuração, o que torna a coleta reprodutível. Por demandar muito tempo, esta foi executada fora do relatório, com os scripts completos disponíveis na pasta `coleta/` que acompanha este trabalho (coleta por instância em processos paralelos, com retomada das instâncias concluídas e mesclagem com verificação de consistência). O bloco abaixo reproduz o núcleo da coleta de uma instância e não é executado na compilação.

```
suppressPackageStartupMessages({library(ExpDE); library(smoof)})

semente <- 20261011

recpars <- list(Config1 = list(name = "recombination_arith"),
                Config2 = list(name = "recombination_bin", cr = 0.7))
mutpars <- list(Config1 = list(name = "mutation_rand", f = 4),
                Config2 = list(name = "mutation_best", f = 3))
configs <- names(mutpars)

coleta_instancia <- function(k) {
  d  <- dims[k]
  f  <- smoof::makeRosenbrockFunction(dimensions = d)
  # O ExpDE localiza a função objetivo pelo nome, no ambiente global
  fn <<- function(X) {
    if (!is.matrix(X)) X <- matrix(X, nrow = 1)
    apply(X, MARGIN = 1, FUN = f)
  }
  selpars  <- list(name = "selection_standard")
  stopcrit <- list(names = "stop_maxeval", maxevals = 5000 * d,
                   maxiter = 100 * d)
  probpars <- list(name = "fn", xmin = rep(-5, d), xmax = rep(10, d))

  obs <- matrix(NA_real_, n_reps, length(configs),
                dimnames = list(NULL, configs))
  for (r in seq_len(n_reps)) {
    for (cfg in seq_along(configs)) {
```

```
      set.seed(semente + 100000L * k + 100L * r + cfg)
      obs[r, cfg] <- ExpDE(mutpars = mutpars[[cfg]], recpars = recpars[[cfg]],
                           popsize = 5 * d, selpars = selpars,
                           stopcrit = stopcrit, probpars = probpars,
                           showpars = list(show.iters = "none"))$Fbest
    }
  }
  data.frame(dimensao = d, instancia = k,
             repeticao = rep(seq_len(n_reps), times = length(configs)),
             configuracao = rep(configs, each = n_reps),
             Fbest = as.vector(obs))
}

bruto <- do.call(rbind, lapply(seq_len(N), coleta_instancia))
write.csv(bruto, "DadosDEGrupoA_bruto.csv", row.names = FALSE)
```

Análise exploratória

Os dados foram carregados e organizados conforme descrito no Desenho experimental:

```
bruto <- read.csv("DadosDEGrupoA_bruto.csv")

# Média e variância das repetições de cada configuração em cada instância
resumo <- aggregate(Fbest ~ instancia + dimensao + configuracao, data = bruto,
                    FUN = function(x) c(media = mean(x), variancia = var(x),
                                        n = length(x)))
resumo <- do.call(data.frame, resumo)
names(resumo) <- sub("^Fbest\\.", "", names(resumo))

# Conferência dos dados contra o desenho experimental
stopifnot(length(unique(resumo$instancia)) == N,
          all(sort(unique(resumo$dimensao)) == dims),
          all(resumo$n == n_reps))

# Formato largo: uma linha por instância, com a média de cada configuração
inst <- merge(
  resumo[resumo$configuracao == "Config1", c("instancia", "dimensao", "media", "variancia")],
  resumo[resumo$configuracao == "Config2", c("instancia", "dimensao", "media", "variancia")],
  by = c("instancia", "dimensao"), suffixes = c("1", "2"))
inst <- inst[order(inst$dimensao), ]

inst$D   <- inst$media1 - inst$media2      # D < 0: Config1 melhor
inst$Rel <- inst$D / inst$media2           # diferença relativa à Config2
```

O código lê o arquivo de dados, calcula a média e a variância amostral das 50 repetições de cada configuração em cada instância, confere o número de instâncias, as dimensões e o número de repetições contra o desenho, e organiza as médias por instância no *data frame* `inst`, com a diferença D_j (`D`) e a diferença relativa à Config2, $D_j/\bar{Y}_{2j}$ (`Rel`).

```
v   <- list(inst$media1, inst$media2, inst$D)
fmt <- function(x) formatC(x, format = "e", digits = 2)
tab <- data.frame(
  Variavel = c("Config1", "Config2", "D"),
  Media    = fmt(sapply(v, mean)),
```

```
  DP       = fmt(sapply(v, sd)),
  Mediana  = fmt(sapply(v, median)),
  Min      = fmt(sapply(v, min)),
  Max      = fmt(sapply(v, max)))
knitr::kable(tab, row.names = FALSE, align = "lrrrrr",
             caption = paste("Estatísticas descritivas, sobre as instâncias,",
                             "das médias do melhor valor por configuração",
                             "e das diferenças D = Config1 - Config2"))
```

Tabela 1: Estatísticas descritivas, sobre as instâncias, das médias do melhor valor por configuração e das diferenças D = Config1 - Config2

Variavel	Media	DP	Mediana	Min	Max
Config1	3.23e+04	4.16e+04	1.08e+04	0.00e+00	1.35e+05
Config2	4.86e+06	3.80e+06	4.69e+06	2.16e+01	1.15e+07
D	-4.83e+06	3.76e+06	-4.68e+06	-1.13e+07	-2.16e+01

A Tabela 1 mostra que os valores obtidos pela Config2 são, em média, cerca de 150 vezes maiores que os da Config1. A Config1 obteve o menor valor médio em 34 das 34 instâncias. Na instância de dimensão 2, a Config1 atingiu o mínimo global em todas as 50 execuções.

```
long <- data.frame(dimensao = rep(inst$dimensao, 2),
                   Config   = rep(c("Config1", "Config2"), each = N),
                   media    = c(inst$media1, inst$media2))
ggplot(long[long$media > 0, ], aes(x = dimensao, y = media, colour = Config)) +
  geom_point() + geom_line(alpha = 0.5) +
  scale_y_log10() +
  labs(x = "Dimensão", y = "Média do melhor valor", colour = NULL) +
  theme_minimal()
```

```
ggplot(inst, aes(x = dimensao, y = D)) +
  geom_point() +
  geom_hline(yintercept = 0, linetype = 2) +
  labs(x = "Dimensão", y = "D") +
  theme_minimal()
```

Na Figura 1, as duas configurações pioram com o aumento da dimensão, mas a Config1 permanece abaixo da Config2 em toda a faixa. Na Figura 2, a diferença D_j é negativa em todas as instâncias e cresce em módulo com a dimensão. A diferença relativa, por outro lado, é praticamente constante: a redução do valor médio obtida pela Config1 em relação à Config2 variou entre 98.83% e 100.00% nas 34 instâncias.

Análise Estatística

Validação das premissas do modelo

O teste t pareado pressupõe que as diferenças D_j sejam independentes e aproximadamente normais. No teste de Shapiro-Wilk, a hipótese nula corresponde à premissa satisfeita; por isso, o teste foi combinado com a análise gráfica.

```
par(mar = c(4, 4, 1, 1))
qqPlot(inst$D, pch = 16, las = 1, id = FALSE,
       xlab = "Quantis da Normal", ylab = "D")
```

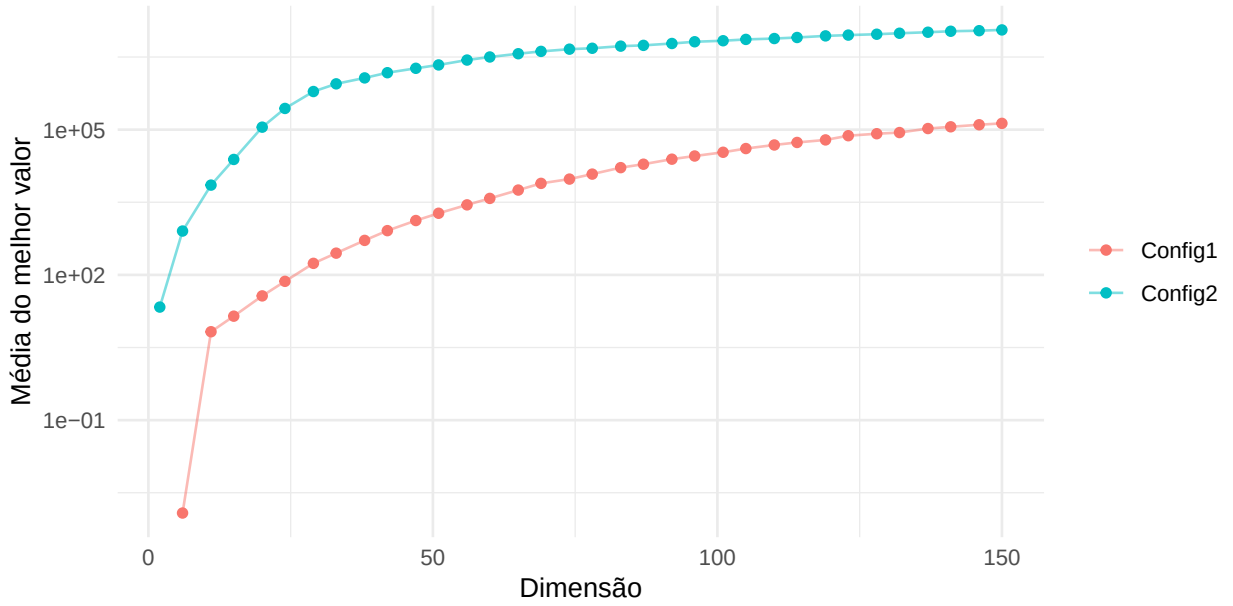


Figura 1: Média do melhor valor da função objetivo por instância, em função da dimensão (eixo vertical em escala logarítmica; o valor nulo da Config1 na dimensão 2 não é representável e foi omitido)

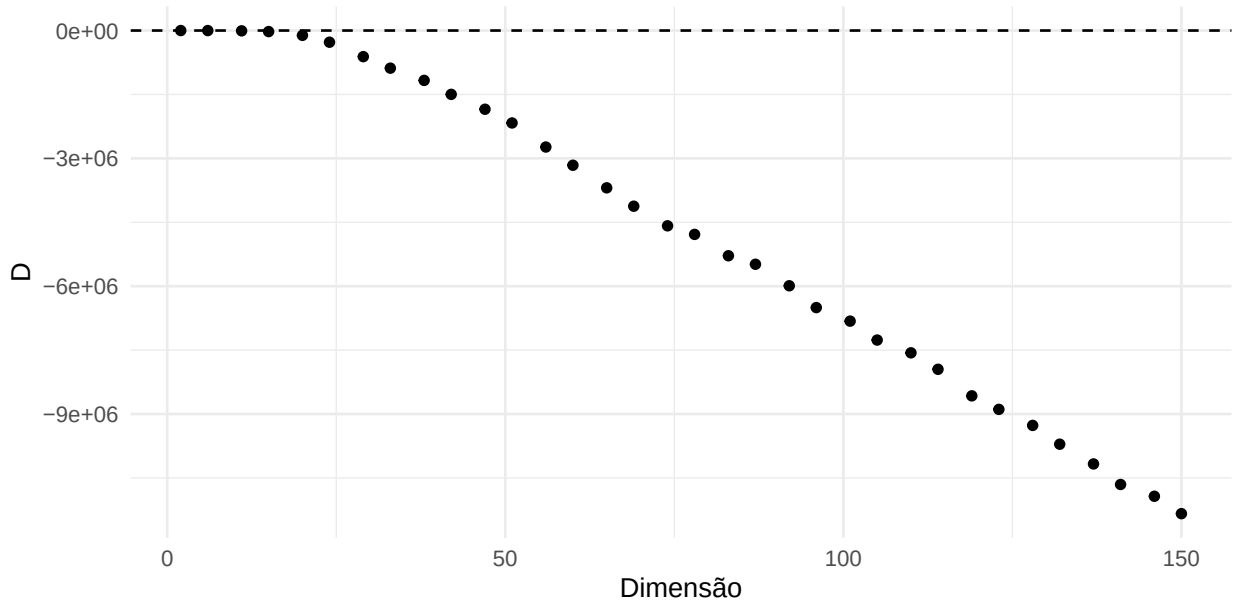


Figura 2: Diferença D (Config1 - Config2) por instância, em função da dimensão (linha tracejada: diferença nula)

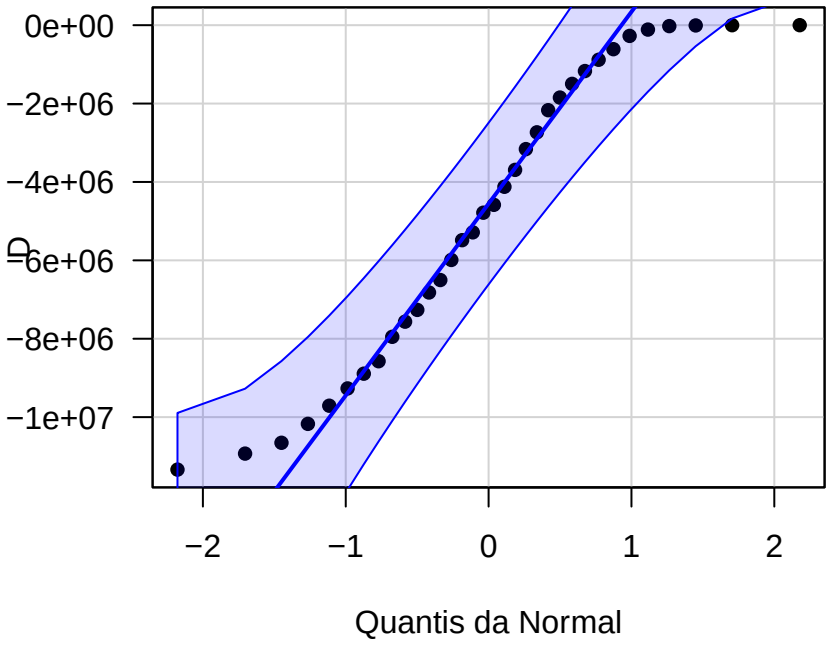


Figura 3: Gráfico quantil-quantil das diferenças D

```
sw <- shapiro.test(inst$D); sw
```

```
##
##  Shapiro-Wilk normality test
##
## data:  inst$D
## W = 0.9231, p-value = 0.01978
```

Normalidade. O teste de Shapiro-Wilk rejeita a normalidade das diferenças ($p = 0.02$). No gráfico quantil-quantil (Figura 3), os pontos centrais acompanham a reta, e o afastamento ocorre nos extremos: nas duas caudas, os valores observados são menos extremos que os esperados sob a distribuição normal, e, na cauda superior, eles se acumulam próximos de zero, valores correspondentes às instâncias de menor dimensão (Figura 2). Trata-se, portanto, de um desvio da normalidade nas caudas, sem assimetria acentuada.

Nessa situação, o teste t é robusto à violação da normalidade, desde que os dados sejam balanceados (Montgomery 2005), o que ocorre neste delineamento: as duas configurações foram avaliadas nas mesmas 34 instâncias, com 50 execuções cada, resultando em exatamente uma diferença por instância. Ainda assim, a conclusão do teste t é verificada adiante pelo teste do sinal, que não depende da distribuição das diferenças.

Independência. Cada instância corresponde a uma dimensão distinta, e cada execução usa uma semente própria, de modo que não há ordenação temporal nem compartilhamento de execuções entre instâncias. A premissa é, portanto, sustentada pelo procedimento de coleta.

Precisão das estimativas por instância. O critério $se_j^2 \leq 0.1\,\sigma_D^2$ adotado no Desenho experimental foi verificado em cada instância, com σ_D^2 estimada pela variância amostral das diferenças.

```
se2_j <- (inst$variancia1 + inst$variancia2) / n_reps
razao_se <- se2_j / var(inst$D)
c(var_D = var(inst$D), max_se2 = max(se2_j),
  max_razao = max(razao_se), media_razao = mean(razao_se))
```

```
##        var_D      max_se2    max_razao  media_razao
```

```
## 1.414703e+13 1.445981e+10 1.022110e-03 3.820449e-04
```

A razão $se_j^2/\hat{\sigma}_D^2$ é no máximo 0.0010 (média de 0.0004), muito abaixo do limite de 0.1.

Vale ressaltar que a expressão de se_j supõe que a distribuição amostral das médias de cada configuração em cada instância seja aproximadamente normal (Campelo e Takahashi 2019). Pelo Teorema Central do Limite, com $r = 50$ execuções, ela é razoável mesmo para distribuições assimétricas de Y, acima do mínimo de 20 a 30 execuções sugerido pelos autores nesses casos.

Apenas por rigor, como algumas instâncias apresentam assimetria acentuada, se_j também foi estimado por bootstrap não paramétrico, procedimento proposto pelos mesmos autores para os casos em que essa suposição não pode ser garantida: em cada instância, as execuções de cada configuração foram reamostradas com reposição $R = 999$ vezes, e se_j foi estimado pelo desvio-padrão das diferenças entre as médias reamostradas.

```
set.seed(2026)  # reamostragem bootstrap
R <- 999
se_boot <- sapply(inst$instancia, function(k) {
  x1 <- bruto$Fbest[bruto$instancia == k & bruto$configuracao == "Config1"]
  x2 <- bruto$Fbest[bruto$instancia == k & bruto$configuracao == "Config2"]
  sd(replicate(R, mean(sample(x1, replace = TRUE)) -
                  mean(sample(x2, replace = TRUE))))
})
c(min_razao_boot_form = min(se_boot / sqrt(se2_j)),
  max_razao_boot_form = max(se_boot / sqrt(se2_j)),
  max_razao_criterio  = max(se_boot^2) / var(inst$D))
```

```
## min_razao_boot_form max_razao_boot_form  max_razao_criterio
##        0.9420843413        1.0320742918        0.0009908638
```

As estimativas por bootstrap ficaram entre 0.94 e 1.03 vezes as obtidas pela expressão analítica, e a razão $se_j^2/\hat{\sigma}_D^2$ calculada com elas é no máximo 0.0010. O critério é, portanto, atendido com ou sem a suposição de normalidade das médias: a variância das diferenças reflete quase exclusivamente a variação do efeito entre instâncias, e o número de repetições adotado é suficiente para que o ruído de cada execução não afete a potência do teste.

Teste t pareado

O teste e as quantidades citadas no Resumo e nas Conclusões foram calculados antecipadamente, pois o Resumo depende de seus resultados:

```
tt
```

```
##
##  One Sample t-test
##
## data:  inst$D
## t = -7.4815, df = 33, p-value = 1.336e-08
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
##  -6138295 -3513568
## sample estimates:
## mean of x
##  -4825931
```

```
round(c(media_D = mean(inst$D), IC_inf = tt$conf.int[1],
        IC_sup = tt$conf.int[2], d_obs = d_obs), 3)
```

```
##      media_D       IC_inf       IC_sup        d_obs
## -4825931.336 -6138294.760 -3513567.912       -1.283
```

A hipótese nula de igualdade de desempenho médio é rejeitada ($t = -7.48$, 33 graus de liberdade, $p = 1.34 \times 10^{-8}$). A diferença média estimada é $\bar{D} = -4.83 \times 10^6$ (IC 95%: $[-6.14 \times 10^6; -3.51 \times 10^6]$), favorável à Config1. Em unidades do desvio-padrão das diferenças, o efeito estimado é $\hat{d} = -1.28$, de módulo superior a $d^* = 0.5$, o que indica uma diferença também relevante do ponto de vista prático.

Como a magnitude de $\bar{D}$ é dominada pelas instâncias de maior dimensão (Figura 2), ela deve ser lida em conjunto com a diferença relativa, que mostra que a vantagem da Config1 não se restringe a essas instâncias: o valor médio obtido pela Config1 foi de 0.00% a 1.17% do obtido pela Config2 em cada instância.

Verificação pelo teste do sinal

Embora a rejeição da normalidade das diferenças se deva a desvios nas caudas, situação em que o teste t é robusto para dados balanceados, a conclusão também foi verificada pelo teste do sinal, que exige apenas observações independentes de uma distribuição contínua. O teste avalia a mediana θ_D das diferenças:

$$\begin{cases} H_0 : \theta_D = 0 \\ H_1 : \theta_D \neq 0 \end{cases}$$

Sob H_0, o número de diferenças positivas r^+ segue uma distribuição binomial $B(N, 0.5)$, e o p-valor bilateral é obtido a partir dela. Importante pontuar que o teste do sinal é menos sensível que o teste t: sua eficiência relativa assintótica em relação ao teste t é de apenas $2/\pi \approx 0.637$, e Campelo e Takahashi (2019) observam que ele exige mais de 50% de instâncias adicionais para a mesma potência: cerca de $N/0.637 = 54$ em vez de $N = 34$. Assim, ele é usado aqui apenas como verificação da conclusão do teste t, e não como teste principal.

```
r_mais <- sum(inst$D > 0)
p_sinal <- 2 * pbinom(min(r_mais, N - r_mais), N, 0.5)
c(r_mais = r_mais, N = N, p_valor = p_sinal)
```

```
##       r_mais            N      p_valor
## 0.000000e+00 3.400000e+01 1.164153e-10
```

Nenhuma das 34 diferenças é positiva, e o teste do sinal rejeita a hipótese de mediana nula ($p = 1.16 \times 10^{-10}$), coincidindo portanto com a conclusão do teste t.

Conclusões e Recomendações

- Ao nível $\alpha = 0.05$, rejeita-se a hipótese de que as duas configurações tenham o mesmo desempenho médio na classe de funções de Rosenbrock com dimensão entre 2 e 150 ($p = 1.34 \times 10^{-8}$).
- A Config1 apresentou o melhor desempenho médio. A diferença média estimada é de -4.83×10^6 (IC 95%: $[-6.14 \times 10^6; -3.51 \times 10^6]$), com efeito padronizado $\hat{d} = -1.28$. A vantagem é consistente ao longo da classe: a Config1 foi melhor em 34 das 34 instâncias, com valores médios inferiores a 1.2% dos obtidos pela Config2 em cada uma delas.
- **Recomendação:** recomenda-se a Config1, cuja vantagem é estatisticamente significativa, de magnitude superior à mínima diferença de importância prática e observada em toda a faixa de dimensões avaliada.
- **Limitações:**
  (i) as conclusões valem apenas para a classe de funções e o orçamento computacional definidos (função de Rosenbrock com dimensão entre 2 e 150 e $5000 \times d$ avaliações da função objetivo por execução, em que d é a dimensão da instância), e não se estendem a funções com outras características nem a orçamentos diferentes;
  (ii) as configurações foram comparadas com valores fixos de parâmetros, previamente ajustados, de modo que o resultado se refere a essas configurações específicas, e não aos operadores de mutação e de recombinação em geral;
  (iii) o desempenho foi medido apenas pelo melhor valor da função objetivo ao final da execução, sem considerar a velocidade de convergência ao longo da busca;

(iv) como D_j cresce em módulo com a dimensão, a diferença média $\bar{D}$ não descreve a vantagem em uma instância específica, e seu valor depende da faixa de dimensões que define a classe.

- **Melhorias:**
  (i) repetir a comparação em outras classes de funções de teste e com outros orçamentos computacionais, para verificar se a vantagem da Config1 se mantém;
  (ii) investigar separadamente o efeito dos operadores de mutação e de recombinação, por meio de um experimento fatorial com esses dois fatores, o que permitiria identificar qual deles é responsável pela diferença observada;
  (iii) registrar a evolução do melhor valor ao longo das avaliações, de modo a comparar também a velocidade de convergência das configurações;
  (iv) determinar o número de repetições pelo procedimento iterativo de Campelo e Takahashi (2019), o que reduziria o custo computacional da coleta, já que o critério de precisão foi atendido com ampla margem.

Referências

Bossek, Jakob. 2017. "smoof: Single- and Multi-Objective Optimization Test Functions". *The R Journal* 9 (1): 103–13. https://doi.org/10.32614/RJ-2017-004.

Campelo, Felipe. 2018. "Lecture Notes on Design and Analysis of Experiments". Versão 2.12. http://git.io/v3Kh8.

Campelo, Felipe, e Moisés Botelho. 2016. "Experimental Investigation of Recombination Operators for Differential Evolution". *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO 2016)*, 221–28. https://doi.org/10.1145/2908812.2908852.

Campelo, Felipe, e Fernanda Takahashi. 2019. "Sample Size Estimation for Power and Accuracy in the Experimental Comparison of Algorithms". *Journal of Heuristics* 25 (2): 305–38. https://doi.org/10.1007/s10732-018-9396-7.

Mathews, Paul. 2010. *Sample Size Calculations: Practical Methods for Engineers and Scientists*. MMB.

Montgomery, Douglas C. 2005. *Design and Analysis of Experiments*. 6ª ed. John Wiley & Sons.

Rosenbrock, H. H. 1960. "An Automatic Method for Finding the Greatest or Least Value of a Function". *The Computer Journal* 3 (3): 175–84. https://doi.org/10.1093/comjnl/3.3.175.

Storn, Rainer, e Kenneth Price. 1997. "Differential Evolution: A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces". *Journal of Global Optimization* 11 (4): 341–59. https://doi.org/10.1023/A:1008202821328.

Wolpert, David H., e William G. Macready. 1997. "No Free Lunch Theorems for Optimization". *IEEE Transactions on Evolutionary Computation* 1 (1): 67–82. https://doi.org/10.1109/4235.585893.

Papéis da equipe

- Amanda Bomfim Moitinho: Verificadora
- David Felipe Brochero Giraldo: Relator
- Henrique Marques Cruz: Relator

Declaração sobre o uso de IA generativa e tecnologias assistidas por IA

Durante a preparação deste trabalho, os autores utilizaram o assistente de IA Claude (Anthropic) para auxiliar na estruturação do código de análise estatística em R e revisar a análise, e OpenCode com o modelo

GLM-5.3-Flash (Z.ai) para a escrita dos scripts de automatização da coleta rápida dos dados utilizados neste relatório. Após o uso dessa ferramenta, os autores revisaram e editaram o conteúdo conforme necessário e assumem total responsabilidade pelo conteúdo do relatório.